VLDB 投稿 #1058 修订回复（英文稿中文对照）

感谢审稿人的仔细评阅。这份对照稿先给出结论和新数据，再贴出拟写入论文的段落及其位置。审稿人即使不翻阅论文，也能在回复中核对修改内容。章节和图号沿用投稿稿件；当前投稿 PDF 本身尚未修改。

本回复通用的实验设置

训练实测使用单机 8 张 32 GiB V100；除非另有说明，每卡 batch 为 8,192。输入预先打乱并驻留主机内存；吞吐统计 510 步 GPU 训练窗口，包含在线映射与通信，不包含离线规划、输入准备、初始化和验证。RAPID 针对 Row-wise embedding 分片优化，因此 TorchRec 采用全 Row-wise 对照。HugeCTR、TorchRec、EMBark、Herald、BagPipe 与 RAPID 使用 AdaGrad 0.01；HET-GMP 的共享表使用其原生 SGD 0.01，标注的 Kaggle/DCN 运行例外。投稿论文原本使用 8 张 16 GiB PCIe V100；当前 32 GiB 机器上的结果是新增实测，不能称为相同硬件的逐值复现。

拟写入论文的位置：Section 7.1，“Hardware and Training Configuration”现有硬件段落之后。

> 修订实验另外使用单机 8 张 32 GiB V100。除非另有说明，每 rank 每步处理 8,192 条样本。输入在训练前打乱并预载入内存。报告的吞吐统计 510 步 GPU 训练，包括在线 ID 映射、调度和通信，不包括一次性预处理、初始化和验证。RAPID 优化 Row-wise embedding 放置，因此 TorchRec 对照使用 Row-wise 分片方案。HET-GMP 的共享表使用原生 SGD、学习率 0.01；其他系统使用 AdaGrad、学习率 0.01，结果表中注明例外。

Meta Revision 1：外部基线、工作负载与训练结果

回复。 我们增加 TorchRec、EMBark、HET-GMP、Herald、BagPipe 的 8 卡训练实测。RAPID 在表中 12 个数据集 / 模型组合上均有最高的实测吞吐。三组主模型沿用论文的模型规模：Kaggle/DCN 为 26 张表、214 个稀疏特征、dim32、6 层 Cross 和两层 1,024 宽的 deep 分支；Terabyte/DLRM-DCNv2 为 26 张表、214 个稀疏特征、dim32、3 层 Cross、512 维投影及 `[1024,1024,512,256,1]` 顶层 MLP；Taobao/DeepFM 为 4 张表、4 个稀疏特征、dim128、三层 400 宽 deep 分支以及一阶和二阶 FM 项。其余九行为 dim32 扩展模型。

表 R1：8 卡训练实测吞吐（samples/s）。

数据集 / 模型	HugeCTR	TorchRec	EMBark	HET-GMP	Herald	BagPipe	RAPID
Kaggle / DLRM	1,265,110	568,823	1,804,285	629,040	10,459	73,470	2,136,522
Kaggle / DCN，dim32	625,151	560,969	1,701,025	701,298†	11,319	73,040	2,032,420
Kaggle / Wide&Deep	1,251,291	533,137	1,796,028	775,392	9,848	70,144	2,292,587
Kaggle / DeepFM	1,405,858	556,847	2,111,551	816,947	9,845	71,503‡	2,855,600
Terabyte / DLRM	1,273,833	568,210	1,849,886	653,264	10,459	99,594	2,010,277
Terabyte / DLRM-DCNv2，dim32	546,769	489,409	1,258,722	666,211	12,562	96,550	1,329,655
Terabyte / Wide&Deep	1,262,214	532,223	1,878,571	814,181	10,344	94,800	2,107,001
Terabyte / DeepFM	1,417,189	556,198	2,236,009	867,333	10,377	96,978‡	2,577,394
Taobao / DLRM	4,588,460	2,147,182	4,027,885	3,230,496	415,450	2,064,385	4,947,326
Taobao / DLRM-DCNv2	3,306,323	1,802,251	3,002,414	2,379,513	424,153	1,981,837	3,488,199
Taobao / Wide&Deep	6,472,360	2,393,622	5,305,386	5,532,203	434,392	2,096,891	7,255,623
Taobao / DeepFM，dim128	5,561,281	1,006,574	3,443,948	5,470,898	362,719	1,332,057‡	8,338,178

† 此 Kaggle/DCN 配置的 HET-GMP 在 SGD 0.01 下 loss 发散；该格改用更小的参数初值和 SGD 0.001。‡ 标出的 DeepFM 运行末步 loss 不稳定或偏高，这些格仅为吞吐观察值，不用于精度比较。HugeCTR 的 Kaggle、Terabyte 主模型使用全 Reduction，Taobao 主模型使用全 Unique；RAPID 使用 CPS 和逐表 ACP。其余九行来自已经完成的 dim32 扩展训练。

Herald 新补测主模型采用缓存阈值 100 和每 rank 8 个 LAIA 线程。HET-GMP 的优化器及各系统底层训练执行不同，因此此表比较系统吞吐，不能解释为仅比较 embedding kernel。

T180、T200、T510 使用 HugeCTR 官方合成数据生成器，按各表词表和 hotness 用 Zipf 指数 1.1 采样 ID。原始逐表维度下，完整官方配置在本机无法完成端到端训练：理想均分的 FP32 embedding 权重每卡约需 30.9、48.4、53.4 GiB，尚未计入优化器状态及训练缓冲。T180 生成脚本实际输出 177 张表。因此我们只在每种负载的一个 65,536 样本分片上比较通信量：保留表结构与 hotness，统一 dim32、每卡 batch512，遍历 5 次，共 80 个 global batch。这些不是官方完整配置的吞吐实验。

表 R2：T 系列分片上 8 rank 前向加反向远端 embedding payload（GiB）。

负载	HugeCTR	TorchRec	EMBark	HET-GMP	Herald	BagPipe	RAPID
T180	73.311	96.797	96.797	157.642	241.929	763.835	64.752
T200	76.259	109.375	109.375	52.306	84.617	229.810	37.835
T510	64.700	278.906	278.906	41.318	71.119	226.686	24.024

相同 dim32 Criteo 输入上，RAPID / HET-GMP 的前反向远端传输量分别为 Kaggle 15.066 / 15.829 GiB、Terabyte 10.785 / 11.553 GiB，统计范围为 8 rank、5 次遍历。RAPID 分别减少 4.82% 和 6.65%；Taobao 则由 HET-GMP 传得更少。两者都利用访问关系，但 RAPID 保持原始 global batch 的样本集合，结合 CPS 与逐表 ACP，严格限制主 embedding 容量等量，并且能在不搬迁旧行的条件下放置新 ID。HET-GMP 运行于不同的 Hetu / HetuTable 执行引擎，所以吞吐差距不能只归因于传输量。

拟写入论文的位置：Section 7.1 替换“Baselines”并补充“Models and Datasets”；Section 7.2 原端到端结果之后。

> 我们将 HugeCTR 以外的比较扩展到 Row-wise TorchRec、EMBark、HET-GMP、Herald 与 BagPipe。表 R1 报告 Kaggle、Terabyte、Taobao 上 DLRM、DCN、Wide&Deep、DeepFM 的 8 卡训练实测吞吐。论文三组主模型规模为：Kaggle/DCN（26 表、214 稀疏特征、dim32、6 层 Cross 与两层 1,024 宽 deep 层）；Terabyte/DLRM-DCNv2（26 表、214 稀疏特征、dim32、3 层 Cross、512 维投影、`[1024,1024,512,256,1]` 顶层 MLP）；Taobao/DeepFM（4 表、dim128、三层 400 宽 deep 层及一阶、二阶 FM 项）。其余九组统一 dim32。RAPID 在全部 12 个组合上取得最高实测吞吐。HET-GMP 使用原生共享表 SGD；表中标记的几项基线训练不能提供稳定 loss 下的精度比较。
>
> 对更多表的工作负载，我们用 HugeCTR 生成器，根据各表词表和 hotness 以及 Zipf(1.1) 分布生成 T180、T200、T510。原始维度的官方完整配置超出可用于端到端训练的显存。因此我们在共同的 65,536 样本分片上比较远端 embedding 传输，保留表结构，统一 dim32、每卡 batch512。RAPID 在五次遍历中分别传输 64.752、37.835、24.024 GiB，均低于同一分片上的其他六种方法。分片通信结果不被解释为官方完整配置的训练吞吐。

拟写入论文的位置：Section 8，“Embedding Placement, Caching, and Replication”之后。

> HET-GMP 是 CPS 尤其接近的前人工作：它构建样本与 embedding 的二部图以及 embedding 共现图，并联合划分样本和 embedding 以降低通信。RAPID 的区别是保持每个原始 global batch 的成员不变，在 CPS 后应用逐表 ACP，对主 embedding 实施等量容量约束，并支持不移动已有行的新 ID 放置。Herald 和 BagPipe 采用执行成本不同的缓存和调度路径。我们直接比较这些系统的训练实测吞吐，并在更多表的 T 系列分片上比较远端 embedding 传输；由于训练引擎不同，吞吐差异不能仅归因于放置算法。

Meta Revision 2：物理扩展性的边界

回复。 我们同意审稿人的意见：投稿稿件的 16–128 rank 结果来自访问记录的通信量与负载回放，并非多机运行时间。目前有实测端到端加速证据的只有单机 8 卡。摘要、Section 7.6 与结论将据此收紧；多机吞吐尚未测量。

拟写入论文的位置：替换摘要最后的扩展性句子；替换 Section 7.6 开头段；替换 Section 9 的扩展性结论。

> 摘要： RAPID 在单机 8 卡上提高了实测训练吞吐。16–128 个逻辑 rank 的访问记录回放只报告传输量和负载趋势；尚未测量多机训练加速。

> Section 7.6： 16–128 rank 实验在记录的访问上回放 embedding 放置与样本路由，统计远端 embedding 向量和各 rank 负载，但不在这些规模上执行分布式训练。回放尤其没有测量网络拓扑、竞争、同步或重叠。因此这些结果只支持通信量扩展性的讨论；所有运行时间和加速结论均限于实测的 8 卡服务器。
>
> Section 9： RAPID 的实测训练收益已在单机 8 卡建立。更多逻辑 rank 的研究支持传输量趋势，物理多机扩展性仍待实验验证。

Meta Revision 3：离线计划与增量更新

回复。 我们测试数据持续追加时能否扩展原计划。先从 2,097,152 条预打乱的 Criteo day-6 multi-hot 样本建立初始计划，再依次加入 56 个互不重叠、每个 65,536 条样本的窗口；四种方法都在同一批最后八个窗口 W49–W56 上比较。RAPID 只放置新 ID、调度新增样本；旧行的 owner 和 physical ID 不变，旧行迁移计数为零。增量更新相对哈希放置的全 Unique 将前向远端接收量减少 73.96%，相对保留旧计划且轮流放新 ID 的方案再减少 29.88%。全量重算的通信量更低，但它改变已有计划。这一同日打乱数据的追加实验不代表真实时间漂移，也没有计量规划和分发所需时间。

表 R3：W49–W56 平均每 rank、每步前向从其他 rank 接收的向量数。

策略	新 ID 放置方式	向量数	相对哈希全 Unique 减少
哈希全 Unique	哈希放置	480,344.75	—
保留旧计划	轮流放置	178,368.19	62.87%
RAPID 增量更新	共现感知	125,080.08	73.96%
全量重算	重做全局计划	103,956.46	78.36%

480,344.75 是单向前向、每 rank 每步的远端接收量；若同一 payload 统计前向加反向，约为其两倍，不能混用口径。表 R3 使用同一批样本，测量 payload 与旧行迁移，不测规划耗时。

拟写入论文的位置：Section 7.8，替换“Sustainability under Incremental Data Updates”。

> 我们在预打乱的 Criteo day-6 multi-hot 数据流上测试增量适配：先用 2,097,152 条样本建计划，再追加 56 个互不相交的 65,536 样本窗口。在相同的末八个窗口上比较哈希放置的全 Unique、保留旧计划且轮流放新 ID、RAPID 的共现感知增量放置，以及全量重算。其平均前向远端接收量分别是每 rank 每步 480,344.75、178,368.19、125,080.08、103,956.46 个向量。RAPID 增量路径相对哈希全 Unique 减少 73.96%，相对保留旧计划减少 29.88%。增量路径不改变任何旧行的 owner 或 physical ID，因此旧行迁移量为零。这些窗口测试的是同一天打乱数据的规模增长，不是真实时间分布漂移；比较也不包括重新规划与分发计划所需的时间。

Meta Revision 4：batch size、峰值负载与规划参数

回复。 Batch size 影响批内去重。在相同 262,144 条 Criteo 样本和 8 个逻辑 rank 上，每卡 batch 从 512 增至 16,384，RAPID 每样本的前向远端接收量从 20.485 降到 5.965 个向量；相对全 Unique 的减少比例从 77.30% 增至 88.36%。每档全 Unique 都按同样 batch 重新计数。这里测的是通信敏感性，没有测不同 batch 的吞吐或梯度累积效果。

表 R4：Batch size 消融；每样本前向远端接收向量数。

每卡 batch	全 Unique	RAPID	RAPID 减少
512	90.250	20.485	77.30%
1,024	82.145	17.070	79.22%
2,048	74.045	13.170	82.21%
4,096	66.145	10.380	84.31%
8,192	58.540	7.960	86.40%
16,384	51.230	5.965	88.36%

三个真实数据上，最忙 rank 的接收量最多是均值的 1.197 倍。主 embedding 的行数严格等量分配，rank 间最多差一行；这里的存储数值不包含优化器状态和通信缓冲。

表 R5：8 rank 峰值前向接收负载与主 embedding 容量。

数据集	平均每 rank / 步向量	最忙 rank / 步	接收峰均比	主 embedding 行数 / rank，最少–最多	存储峰均比
Kaggle	98,739.62	103,057.56	1.044	2,409,915–2,409,916	1.000000207
Terabyte	70,678.40	84,585.56	1.197	2,682,414–2,682,415	1.000000326
Taobao	5,829.11	6,003.38	1.030	120,622–120,623	1.000002073

参数实验默认 β=0.0001、γ=0.2、hot-ID Top-K=40,000，每次只改一项。“profiling 批次逆序”只倒转建立计划时输入统计 batch 的处理顺序，不改变训练样本或训练 batch。六位小数精度下，所有设置的主 embedding 存储峰均比均为 1.000000。

表 R6：单项参数改动对每样本前向远端接收量的影响。

规划设置	向量 / 样本	相对默认变化	主存储峰均比
默认	7.962	—	1.000000
γ=0	11.635	+46.1%	1.000000
β=0	8.097	+1.7%	1.000000
hot Top-K=100,000	8.938	+12.3%	1.000000
profiling 批次逆序	7.976	+0.2%	1.000000

拟写入论文的位置：Section 7.8，“Load Balance”之后；Section 5.2，CPS 算法之后补充参数。

> 在相同 262,144 条 Criteo 样本、8 个 rank 上改变每卡 batch，并为每档重新计算全 Unique 对照。每卡 batch 从 512 增至 16,384，RAPID 每样本前向远端接收量从 20.485 降至 5.965 个向量，相对全 Unique 的减少比例从 77.30% 增至 88.36%。更大的 batch 提供更多批内重复 ID 去重机会。本实验统计传输量，不测逐 batch 训练吞吐或梯度累积。
>
> Kaggle、Terabyte、Taobao 上最忙 rank 的每步前向远端接收量分别为均值的 1.044、1.197、1.030 倍。主 embedding 存储受到容量约束，各 rank 最大与最小分配量最多差一行，峰均比分别为 1.000000207、1.000000326、1.000002073。这里不包含优化器状态和临时缓冲。
>
> 默认设置 β=0.0001、γ=0.2、hot-ID Top-K=40,000。默认每样本前向远端接收量为 7.962 个向量；γ=0、β=0、Top-K=100,000、profiling 批次逆序时分别为 11.635、8.097、8.938、7.976。等量容量约束使所有情况下的主 embedding 行数保持均衡。逆转 profiling 顺序不改变训练样本或 global batch。

Meta Revision 5：冷 ID 共现与精度

回复。 我们回应“高共现比是否只因 ID 出现一两次”的疑问。在 2,097,152 条 Criteo multi-hot 样本上，出现于不到 0.01% 样本（少于 210 条）的 ID 定义为冷 ID。支持次数是包含某 ID 的不同样本数，同一条样本内重复出现只算一次。对每个目标冷 ID，MCR 等于它与任一其他冷 ID 的最大共同出现次数除以目标支持次数。最低支持次数为 100 时，只保留出现 100–209 次的冷目标；其中 85.50% 的 MCR 仍大于 95%。这是特定工作负载统计：multi-hot 扩展本身可能产生确定性共现，因此不能将这个比例直接推广到未扩展的类别数据或未来时间窗口。

表 R7：所测 multi-hot 负载中 MCR>95% 的冷 ID。

目标最低支持次数	合格冷 ID 数	MCR>95% 的 ID 数	比例
10	1,886,103	1,333,054	70.68%
20	953,848	770,892	80.82%

目标最低支持次数	合格冷 ID 数	MCR>95% 的 ID 数	比例
50	353,257	299,515	84.79%
100	129,222	110,490	85.50%

RAPID 保持每个原始 global batch 的样本集合，只改变样本分配到哪个 rank。在样本计算不依赖 rank 且优化器更新语义相同的前提下，batch 目标与全局梯度在数学上不变，浮点归约顺序除外；这一论证不保证 rank 局部状态或随机算子下逐位一致。完整 Taobao/DLRM 一轮训练使用 23,920,640 条训练、2,621,440 条验证样本，三个配对种子下 HugeCTR 与 RAPID 的平均 AUC 为 0.657161 和 0.657166。配对平均差（RAPID 减 HugeCTR）为 +0.000004，95% 置信区间 [–0.000215, +0.000223]。区间包含零，但不等于证明两者等效。

下表其他 12 组组合仅在 983,040 条训练样本上进行510 步短训、五种子配对，不是完整数据集收敛测试。所有配对差区间都跨零，但若干区间较宽，因此只作为有限的精度检查。LogLoss 从截断后的预测概率计算。

表 R8：510 步后的留出集 AUC 和 LogLoss；AUC 配对差为 RAPID 减 HugeCTR。

数据集 / 模型	HugeCTR AUC	RAPID AUC	平均配对差 [95% 区间]	LogLoss，HugeCTR / RAPID
Kaggle / DLRM	0.626839	0.625624	–0.001216 [–0.010125, +0.007693]	2.320256 / 2.417471
Kaggle / DLRM-DCNv2	0.637947	0.640222	+0.002275 [–0.001915, +0.006466]	1.430427 / 1.357891
Kaggle / Wide&Deep	0.660461	0.659502	–0.000959 [–0.004375, +0.002456]	1.234775 / 1.233248
Kaggle / DeepFM	0.667539	0.667832	+0.000293 [–0.000472, +0.001059]	0.862612 / 0.862193
Terabyte / DLRM	0.589586	0.589612	+0.000026 [–0.008002, +0.008054]	0.493343 / 0.514816
Terabyte / DLRM-DCNv2	0.600504	0.601417	+0.000912 [–0.003169, +0.004993]	0.396073 / 0.393783
Terabyte / Wide&Deep	0.601201	0.600938	–0.000263 [–0.001930, +0.001405]	0.394008 / 0.401402
Terabyte / DeepFM	0.611441	0.611374	–0.000066 [–0.000578, +0.000446]	0.248894 / 0.249281
Taobao / DLRM	0.565991	0.566503	+0.000511 [–0.000519, +0.001542]	0.689493 / 0.689298
Taobao / DLRM-DCNv2	0.560156	0.560812	+0.000656 [–0.001369, +0.002681]	1.286928 / 1.267466
Taobao / Wide&Deep	0.568817	0.568714	–0.000103 [–0.000556, +0.000349]	1.250600 / 1.246514
Taobao / DeepFM	0.568164	0.568066	–0.000099 [–0.001140, +0.000943]	1.295433 / 1.281402

拟写入论文的位置：Section 5.1，MCR 定义和 Figure 6(c) 之后；Section 4.1，替换精度保持的限定表述；Section 7.3，补充新精度结果。

> 我们检验高 MCR 是否只由出现一两次的 ID 推动。在 2,097,152 条 Criteo multi-hot 样本上，目标 ID 的支持次数定义为包含它的不同样本数，冷 ID 定义为出现在少于 0.01% 样本中的 ID。目标冷 ID 的最低支持次数设为 10、20、50、100 时，MCR>95% 的比例分别为 70.68%、80.82%、84.79%、85.50%；最高阈值对应出现 100–209 次的目标。这证明所生成 multi-hot 负载中的统计现象；扩展规则本身可能引入共现，因此不能据此认定未扩展类别数据具有相同比例。
>
> RAPID 保持每个原始 global batch 的成员不变，只改变它们被分配到哪个 rank。在样本计算与 rank 无关、优化器语义相同的条件下，batch 目标与总梯度在数学上不变；浮点归约顺序及 rank 局部状态仍可能导致实现层面的差异。因此我们用实测检查模型精度，而不声称训练逐位一致。

> 在完整 Taobao/DLRM 一轮训练中，训练和验证样本分别为 23,920,640 与 2,621,440 条；三个配对种子得到 HugeCTR、RAPID 的平均验证 AUC 为 0.657161、0.657166。平均配对差为 +0.000004，95% 区间 [–0.000215, +0.000223]。另在 12 个数据集 / 模型组合上进行五种子、510 步检查，全部 AUC 配对差区间都包含零；这些短训用于模型覆盖检查，不证明完整收敛或统计等效。

Meta Revision 6：修正 Figure 4 与公式 (5) 的计数口径

回复。 Reviewer 5 指出的问题成立：投稿 Figure 4(b) 的 Reduction 曲线只数非空远端 owner 的贡献，因而不同表数值不同；公式 (5) 对应的是固定长度聚合输出。我们将 Figure 4(b)–(c) 与 Figure 11 的全 Reduction 曲线统一为前向从其他 rank 接收的口径。每卡 batch B=8,192、G=8 rank 时，每表每 rank 的 Reduction 远端传输量为 B(G–1)=57,344 个向量，26 表共 1,490,944 个。公式 (5) 的 BG=65,536 还包含本地项，扣除 B 才是远端 payload。Figure 4(c) 旧图约 567,000 的总量来自非空 owner 计数，不是固定 Reduction 的传输量。HugeCTR 的embedding 通信实现在这一路径按固定输出向量交换。

统计口径，B=8,192、G=8	每表每 rank	26 表
全部聚合项，含本地	65,536	1,703,936
前向从其他 rank 接收向量	57,344	1,490,944

拟写入论文的位置：Section 3.2，替换 Figure 4(b)–(c) 及图注；Section 6.1，公式 (5) 后；Section 7.4，替换 Figure 4 的讨论；Figure 11 修正全 Reduction 数值。

> 公式 (5) 每表每接收 rank 计算 B·G 个聚合输出位置，其中 B 个在本地产生。比较 embedding 传输量时，我们统一只计算从其他 rank 接收的向量，即 B·(G–1)。因此在 8 rank、每卡 batch 8,192 下，固定 Reduction 每表每 rank 传输 57,344 个远端向量，不依赖该表的 ID 分布或 pooling factor；26 表共 1,490,944 个前向远端向量。Figure 4(b)–(c) 与 Figure 11 全 Reduction 曲线使用相同的远端口径。旧 Figure 4 的 Reduction 曲线误数非空 owner 的贡献，而非固定聚合输出，现予以替换。

给 Reviewer 2 的逐条回复

R1，外部比较。 Meta Revision 1 给出七系统实测吞吐（表 R1）、T 系列组件通信比较（表 R2），以及 Section 7.1、7.2、8 的拟修改原文；HET-GMP 的优化器与执行引擎差异在结果旁说明。

R2，物理扩展。 Meta Revision 2 直接贴出摘要、Section 7.6 和结论的替换文字，将实测加速限定为 8 卡，将 16–128 rank 明确为访问记录的传输量实验。

R3，时间稳健性。 Meta Revision 3 展示同窗口四策略比较、旧行零迁移，以及同日打乱数据追加不能代表真实时间漂移、尚未计量规划耗时的边界；并给出 Section 7.8 替换段落。

R4，batch 与峰值。 Meta Revision 4 给出 batch 通信敏感性、最忙 rank 的绝对接收量与存储不平衡，以及 Section 5.2 / 7.8 的修改文字；没有把通信计数当作吞吐或梯度累积实验。

R5，精度。 Meta Revision 5 给出 Section 4.1 / 7.3 的修改文字、一组完整 Taobao 一轮三种子对比，并将其余 12 组正确标为五种子短训。

给 Reviewer 3 的逐条回复

物理扩展与冷 ID 证据。 Meta Revisions 2、5 在准确的论文位置提供替换表述。MCR 表排除了低支持次数目标，并将结论限定于生成的 multi-hot 数据。

负载感知前人方法。 Meta Revision 1 将 HET-GMP 加入实验与 Section 8 相关工作，说明其共现图划分与 RAPID 在 global batch、ACP、容量和增量放置上的区别。

参数与顺序。 Meta Revision 4 写明默认 β、γ、Top-K、单项通信变化和“profiling 逆序”的含义，并提供 Section 5.2 的拟修改文字；没有声称未测的最优性或 METIS 种子敏感性。

给 Reviewer 5 的逐条回复

最近的前人工作与更广泛的评估。 Meta Revision 1 给出 HET-GMP 的区别、七系统结果、Taobao 工作负载和 T 系列分片；Meta Revision 2 明确硬件边界。Section 8 的相关工作改写全文已贴在本回复中。

Figure 4 与公式 (5)。 Meta Revision 6 给出修正口径、每表 57,344 和总量 1,490,944，以及 Figure 4、Figure 11 和 Section 6.1 的具体替换文字。

研究挑战。 拟写入 Section 8 的段落明确 RAPID 相比共现图放置还提供逐表策略选择、保持原 global batch、严格均衡行容量，以及无需搬迁旧行的新 ID 放置。