Revision of VLDB Submission #1058

感谢各位审稿人的建议。以下先报告共同关注的修订结果，再逐条回答具体意见。

实验设置

端到端实验采用 8 卡 32 GiB V100、每卡 batch 8,192、预打乱的内存输入和 510 步 GPU 训练窗口，计入训练时映射与通信。RAPID 优化 Row-wise 分片，TorchRec 对照也采用全 Row-wise。HET-GMP 的共享表使用 SGD 0.01（表 1 中标注的 Kaggle / DCN 例外），其余方法使用 AdaGrad 0.01。T 系列通信和精度实验的配置见对应段落。

Meta Revision 1：外部基线、工作负载与训练结果

针对外部基线不足的问题，表 1 比较七种方法在 Kaggle、Terabyte、Taobao 三种真实数据上的端到端训练吞吐。主模型采用论文中的配置：Kaggle / DCN（26 表、214 稀疏特征、dim32，6 层 Cross 与两层 1024 宽 deep 分支）、Terabyte / DLRM-DCNv2（26 表、214 稀疏特征、dim32，3 层 Cross、512 投影与 `[1024,1024,512,256,1]` 顶层 MLP）、Taobao / DeepFM（4 表、4 稀疏特征、dim128，三层 400 宽 deep 分支及一阶、二阶 FM 项）。其余九组为统一 dim32 的扩展模型。表 1 的 12 组数据 / 模型组合中，RAPID 的实测吞吐均为最高。

表 1　8 卡端到端训练吞吐（samples/s）

数据集 / 模型	HugeCTR	TorchRec	EMBark	HET-GMP	Herald	BagPipe	RAPID
Kaggle / DLRM	1,265,110	568,823	1,804,285	629,040	10,459	73,470	2,136,522
Kaggle / DCN，dim32	625,151	560,969	1,701,025	701,298†	11,319	73,040	2,032,420
Kaggle / Wide&Deep	1,251,291	533,137	1,796,028	775,392	9,848	70,144	2,292,587
Kaggle / DeepFM	1,405,858	556,847	2,111,551	816,947（稳定 BCE）	9,845	71,503（loss 高）	2,855,600
Terabyte / DLRM	1,273,833	568,210	1,849,886	653,264	10,459	99,594	2,010,277
Terabyte / DLRM-DCNv2，dim32	546,769	489,409	1,258,722	666,211	12,562	96,550	1,329,655
Terabyte / Wide&Deep	1,262,214	532,223	1,878,571	814,181	10,344	94,800	2,107,001
Terabyte / DeepFM	1,417,189	556,198	2,236,009	867,333	10,377	96,978（loss 高）	2,577,394
Taobao / DLRM	4,588,460	2,147,182	4,027,885	3,230,496	415,450	2,064,385	4,947,326
Taobao / DLRM-DCNv2	3,306,323	1,802,251	3,002,414	2,379,513	424,153	1,981,837	3,488,199
Taobao / Wide&Deep	6,472,360	2,393,622	5,305,386	5,532,203	434,392	2,096,891	7,255,623
Taobao / DeepFM，dim128	5,561,281	1,006,574	3,443,948	5,470,898	362,719	1,332,057	8,338,178

表 1 的论文主模型行均为相同模型下的 510 步 GPU 训练窗口。HugeCTR 在 Kaggle、Terabyte 主模型采用全 Reduction，在 Taobao 主模型采用全 Unique；RAPID 使用 CPS 与逐表 ACP。其他九组 dim32 行沿用已完成的同结构扩展训练。Herald 与 BagPipe 的旧扩展行来自原配置；新补测的 Herald 主模型使用缓存阈值 100、每 rank 8 个 LAIA 线程。

† Kaggle / DCN 的 HET-GMP 在 SGD 0.01 下 loss 发散；该格使用较小参数初值及 SGD 0.001 完成 510 步。Taobao / DeepFM dim128 的 BagPipe 末步 loss 仍偏高，不用于精度比较。

审稿人还要求更多表的负载。T180、T200、T510 来自 HugeCTR 官方合成数据生成器：按各表词表与 hotness 用 Zipf(1.1) 采样 ID；每个负载原定生成 100 个分片，T180 的脚本实际生成 177 张表。官方完整配置无法在本机完成端到端训练：仅 FP32 embedding 权重理想均分便需每卡约 30.9 / 48.4 / 53.4 GiB，尚未计入优化器和训练缓冲，而 V100 每卡只有 32 GiB。因此我们使用各负载的一个 65,536 样本分片，保留表数与 hotness，统一 dim32、每卡 batch512，比较各方法的通信量；不将缩容实验作为官方完整配置的训练吞吐。

RAPID 在三个 T 系列负载上的远端 embedding 传输量均低于其他六种方法。下表采用同一分片、dim32、每卡 batch512、五次遍历（共 80 个 global batch），按各方法协议统计 8 卡合计的前向与反向远端 embedding 传输量（GiB）。EMBark 的自动规划在三组负载上均选择全 Reduction；BagPipe 的数值包含缓存同步。此表是协议通信量计数，不是 GPU 链路字节或端到端吞吐。

负载	HugeCTR	TorchRec	EMBark	HET-GMP	Herald	BagPipe	RAPID
T180	73.311	96.797	96.797	157.642	241.929	763.835	64.752
T200	76.259	109.375	109.375	52.306	84.617	229.810	37.835
T510	64.700	278.906	278.906	41.318	71.119	226.686	24.024

在相同的 dim32 Criteo 输入上，RAPID 与 HET-GMP 的前反向远端 embedding 传输量分别为 Kaggle 15.066 / 15.829 GiB、Terabyte 10.785 / 11.553 GiB（8 rank、五次遍历）；RAPID 分别减少 4.82% / 6.65%。Taobao 是例外，HET-GMP 的通信量更低。因此通信优势覆盖所测两个 Criteo 输入和三个 T 系列分片，而非所有数据集。

Meta Revision 2：物理扩展性的边界

我们同意审稿人关于物理扩展性的意见：目前没有完成多机或 16–128 GPU 的端到端训练实验。论文中 16–128 rank 的结果只来自访问记录上的通信与负载计数，不能证明大规模部署的实际吞吐或加速。我们将收紧摘要、Section 7.6 和结论中的表述：训练加速只对应已实测的单机 8 卡；更大规模仅报告逻辑 rank 的通信趋势，并将多机物理扩展性列为尚未验证的限制。

Meta Revision 3：离线计划与增量更新

审稿人关心离线计划在数据增长后是否仍有效，以及更新是否需要搬迁已有 embedding。我们在已打乱的 Criteo day6 multi-hot 输入上，从 2,097,152 条初始样本建立计划，再依次加入 56 个互不重叠、每个 65,536 条样本的窗口。增量路径只放置新 ID、调度新增样本；已存在 ID 的 owner 与 physical ID 保持不变，因此本实验没有旧 embedding 的迁移量。表中四种策略在同一批新增窗口上的比较显示，增量通信较纯 Unique 减少约 74%，并接近每轮全量重算。

下表比较四种策略：纯 Unique 使用哈希放置；“不更新放置”沿用原计划，仅轮流分配新 ID；增量更新按新 ID 的访问关系补充放置；全量重算重新规划全部已见数据。每格为 W49–W56 平均每 rank、每步前向远端接收向量数。

策略	放置方式	接收向量 / rank / 步	相对纯 Unique 减少
纯 Unique（W49–W56）	原分配与哈希放置	480,344.75	—
不更新放置	新 ID 轮流放置	178,368.19	62.87%
RAPID 增量更新	新 ID 按访问关系放置	125,080.08	73.96%
全量重算	每轮重做全局计划	103,956.46	78.36%

在同一批样本上，增量更新比不更新放置进一步减少 29.88% 的远端接收量；它比全量重算多 20.32%，但无需搬迁旧 embedding。

Meta Revision 4：batch size、负载与参数敏感性

增大 batch size 会增加批内重复 ID 的去重机会，并进一步扩大 RAPID 相对全 Unique 的通信优势。为检验这一点，我们在同一份 262,144 条 Criteo 输入上固定 8 个 rank，分别以六档每卡 batch size 运行 RAPID；每档都用相同的样本和分批方式重新计算全 Unique 基线。表 2 将各档的前向远端接收向量总数除以处理的样本数，避免因 batch 数不同而混淆通信量比较。这份输入与前述增量实验的 W49–W56 不同，因此两表的全 Unique 数值不必逐值相等。

表 2　Batch size 消融

每卡 batch	全 Unique（向量 / 样本）	RAPID（向量 / 样本）	RAPID 减少
512	90.250	20.485	77.30%

每卡 batch	全 Unique（向量 / 样本）	RAPID（向量 / 样本）	RAPID 减少
1,024	82.145	17.070	79.22%
2,048	74.045	13.170	82.21%
4,096	66.145	10.380	84.31%
8,192	58.540	7.960	86.40%
16,384	51.230	5.965	88.36%

随着每卡 batch 从 512 增至 16,384，RAPID 的远端接收量从 20.485 降至 5.965 向量 / 样本，相对同档全 Unique 的减少比例从 77.30% 升至 88.36%。更大的 batch 让更多重复 ID 落在同一批次内，按批去重后两种方法的单位样本通信量都下降，而 RAPID 的优势继续扩大。

审稿人还担心最忙 rank 的负载抵消平均通信收益。我们逐步统计最忙 rank 的前向接收量：在三组真实数据上，它是各 rank 平均量的 1.030–1.197 倍，未出现极端通信集中。

数据集	平均每 rank / 步	最忙 rank / 步	峰均比
Kaggle	98,739.62	103,057.56	1.044
Terabyte	70,678.40	84,585.56	1.197
Taobao	5,829.11	6,003.38	1.030

主 embedding 放置同时施加严格的等量容量约束：若总条数不能被 8 整除，各 rank 的数量最多相差一条。对上述同一批 8-rank 计划核对最终主 embedding 数量，结果如下；这里不计优化器状态和通信缓冲。

数据集	每 rank 主 embedding 数量（最少–最多）	最大差值	存储峰均比
Kaggle	2,409,915–2,409,916	1	1.000000207
Terabyte	2,682,414–2,682,415	1	1.000000326
Taobao	120,622–120,623	1	1.000002073

审稿人还询问 β、γ、Top-K 与离线统计顺序对计划的影响。以下固定默认 β=0.0001、γ=0.2、hot Top-K=40,000，每次只改一项。“离线 profiling 批次逆序”仅将用于建立计划的 profiling batch 按相反顺序处理，样本及训练 global batch 的组成不变；该项检验计划对统计顺序的敏感性。

单项改动	接收向量 / 样本	相对默认	主存储峰均比
默认	7.962	—	1.000000
γ=0	11.635	+46.1%	1.000000
β=0	8.097	+1.7%	1.000000
hot Top-K=100,000	8.938	+12.3%	1.000000
离线 profiling 批次逆序	7.976	+0.2%	1.000000

上述改动影响通信量，但最终主 embedding 条数仍受同一等量容量约束；表中的峰均比按六位小数显示。

Meta Revision 5：共现统计与精度

审稿人指出，只出现一两次的冷 ID 很容易得到很高的共现比例。我们对论文使用的 Criteo multi-hot 工作负载取 2,097,152 条样本，先按样本统计每个 ID 的出现次数，同一样本内重复出现只计一次。出现频率低于 0.01%（即少于 210 个样本）的 ID 定义为冷 ID。对每个冷 ID，找出与它共同出现在同一样本中次数最多的另一个冷 ID，再用该共同出现次数除以目标 ID 的出现次数，得到 MCR。

表 3 的“目标 ID 至少出现”用于排除证据太少的目标：例如阈值 100 只统计出现 100–209 次的冷 ID；若目标出现 100 次、某个冷伙伴与它同现 96 次，则 MCR=96%。伙伴仍可为任意其他冷 ID。每一档均枚举所有符合条件的目标 ID，而不是抽样。阈值从 10 提高到 100 后，MCR>95% 的比例未下降，说明这一现象在论文的 multi-hot 工作负载中不只来自出现一两次的 ID。

表 3　MCR>95% 的冷 ID

目标 ID 至少出现（样本数）	符合条件的冷 ID	MCR>95% 的冷 ID	比例
10	1,886,103	1,333,054	70.68%
20	953,848	770,892	80.82%
50	353,257	299,515	84.79%
100	129,222	110,490	85.50%

RAPID 只在每个原始 global batch 内重排样本，各样本的出现次数不变；在相同逻辑 ID 初始参数、优化器状态与梯度归约条件下，每步目标函数和全局梯度在数学上保持不变。HET-GMP 的原生样本图分区会改变每步的样本集合，不能提供这一逐步等价保证。审稿人还要求训练精度证据：完整 Taobao / DLRM 数据训练一轮后，RAPID 与 HugeCTR 的验证 AUC 接近。下表最后一列先将三个相同随机种子下的 RAPID AUC 分别减去 HugeCTR AUC，再给出差值的平均数及其 95% 置信区间；区间包含零，表示本次实验未观察到可靠的 AUC 差异。

完整 Taobao / DLRM（一轮，三种子）	HugeCTR AUC	RAPID AUC	AUC 平均差（RAPID 减 HugeCTR；95% 置信区间）
23,920,640 条训练、2,621,440 条验证	0.657161	0.657166	+0.000004 [–0.000215, +0.000223]

为检查其他模型，我们又对 12 个统一 dim32 的扩展组合使用相同样本序列与留出集进行五种子、510 步配对；各组合的 AUC 平均差的 95% 置信区间均包含零。表 4 是短窗口的模型覆盖检查，配置不同于表 1 的 Kaggle / DCN 和 Taobao / DeepFM dim128 主模型。

表 4　扩展组合的留出精度（510 步）

数据集 / 模型	HugeCTR AUC	RAPID AUC	AUC 平均差（RAPID 减 HugeCTR；95% 置信区间）	LogLoss（HugeCTR / RAPID）
Kaggle / DLRM	0.626839	0.625624	-0.001216 [-0.010125, +0.007693]	2.320256 / 2.417471
Kaggle / DLRM-DCNv2	0.637947	0.640222	+0.002275 [-0.001915, +0.006466]	1.430427 / 1.357891
Kaggle / Wide&Deep	0.660461	0.659502	-0.000959 [-0.004375, +0.002456]	1.234775 / 1.233248
Kaggle / DeepFM	0.667539	0.667832	+0.000293 [-0.000472, +0.001059]	0.862612 / 0.862193
Terabyte / DLRM	0.589586	0.589612	+0.000026 [-0.008002, +0.008054]	0.493343 / 0.514816
Terabyte / DLRM-DCNv2	0.600504	0.601417	+0.000912 [-0.003169, +0.004993]	0.396073 / 0.393783
Terabyte / Wide&Deep	0.601201	0.600938	-0.000263 [-0.001930, +0.001405]	0.394008 / 0.401402
Terabyte / DeepFM	0.611441	0.611374	-0.000066 [-0.000578, +0.000446]	0.248894 / 0.249281
Taobao / DLRM	0.565991	0.566503	+0.000511 [-0.000519, +0.001542]	0.689493 / 0.689298
Taobao / DLRM-DCNv2	0.560156	0.560812	+0.000656 [-0.001369, +0.002681]	1.286928 / 1.267466

数据集 / 模型	HugeCTR AUC	RAPID AUC	AUC 平均差（RAPID 减 HugeCTR；95% 置信区间）	LogLoss（HugeCTR / RAPID）
Taobao / Wide&Deep	0.568817	0.568714	-0.000103 [-0.000556, +0.000349]	1.250600 / 1.246514
Taobao / DeepFM	0.568164	0.568066	-0.000099 [-0.001140, +0.000943]	1.295433 / 1.281402

表 4 使用 983,040 条训练样本。

Meta Revision 6：Figure 4 与公式 (5) 的计数修正

审稿人指出 Figure 4(b) 各表 Reduction 计数不同，与公式 (5) 的定长输出不符。图中的 Reduction 曲线误用了非空 owner 数；我们将按公式 (5) 修正为固定长度聚合输出。HugeCTR 的前向 NCCL 实现也按输出向量数发送和接收：8 rank、每卡 batch 8,192 时，每表每 rank 前向远端接收 57,344 个向量。

Response to Reviewer 2

您的建议主要涉及外部基线、真实扩展性、增量计划的有效性、batch 与峰值负载，以及精度证据。我们分别在以下修订中回应。

Revision Request 1（外部比较）—Meta Revision 1：表 1 比较三种真实数据、四种模型上的七种方法；T180、T200、T510 的七方法通信量另列于表后。

Revision Request 2（真实扩展性）—Meta Revision 2：我们没有多机训练结果，将物理加速结论限定于单机 8 卡；16–128 rank 只报告通信与负载计数。

Revision Request 3（增量稳定性）—Meta Revision 3：增量放置只处理新 ID，无须迁移已有 embedding；四策略比较显示其通信量接近全量重算。

Revision Request 4（batch 与峰值）—Meta Revision 4：表 2 显示 batch 增大时 RAPID 的相对通信收益提高；负载与主 embedding 存储的峰均比另列于表后。

Revision Request 5（精度）—Meta Revision 5：完整 Taobao 数据的三种子配对 AUC 接近；扩展组合另有五种子配对结果。

Response to Reviewer 3

您重点询问大规模物理扩展性、冷 ID 共现统计的支持次数、与现有负载感知方法的区别，以及参数和 profiling 顺序的影响。

Revision Request 1（扩展性）—Meta Revision 2：我们尚无多机训练结果，将相应收紧摘要、Section 7.6 和结论中的加速表述。

Revision Request 2（冷 ID 统计）—Meta Revision 5：表 3 枚举所有满足支持次数要求的冷 ID，并报告提高阈值后的 MCR 分布。

Revision Request 3（负载感知方法）—Meta Revisions 1、3、5：与 HET-GMP 和 Herald 的比较见表 1。RAPID 保持每步 global batch 的样本集合，并结合逐表 ACP、严格均衡的主 embedding 放置和新 ID 增量更新。

Revision Request 4（参数与顺序）—Meta Revision 4：消融表给出 β、γ、Top-K 及 profiling 批次顺序的通信量变化。

Response to Reviewer 5

您的建议集中于与 HET-GMP、Herald 等方法的直接比较，扩展数据与硬件证据，以及 Figure 4 与公式 (5) 的一致性。

Detailed Evaluation 1（外部方法与 CPS）—Meta Revisions 1、3、5：我们将明确 HET-GMP 的共现放置与 CPS 的联系。RAPID 还保持原 global batch，支持逐表 ACP、等量主 embedding 放置及增量更新，且无需额外 embedding 镜像；所测 Criteo 两组和 T 系列分片的通信比较见 Meta Revision 1，Taobao 的 HET-GMP 通信更低。按表 1 的 12 组数据计算，RAPID 相对 HET-GMP 的几何平均吞吐比为 2.30×。这一差距不能仅归因于通信：两者分别运行在 HugeCTR 与 Hetu / HetuTable 上，训练执行和共享表更新路径不同，HET-GMP 的优化器也不同。

Detailed Evaluation 2（数据与硬件）—Meta Revisions 1、2：新增 Taobao 训练和 T 系列七方法通信比较；物理吞吐结论限定于单机 8 卡。

Detailed Evaluation 3（公式与图）—Meta Revision 6：按公式 (5) 和 HugeCTR 通信实现修正 Figure 4 的 Reduction 曲线。

Other revisions（研究挑战）—Meta Revisions 1、3、4：明确 RAPID 在固定 global batch 下结合 CPS、逐表 ACP 与增量放置的贡献，并以通信、吞吐和负载结果支持。